

МИНОБРНАУКИ РОССИИ
Федеральное государственное бюджетное образовательное
учреждение высшего образования
«Ярославский государственный университет имени П. Г. Демидова»

Кафедра дискретного анализа

Сдано на кафедру

«_____» _____ 2026 г.

Заведующий кафедрой,

д. ф.-м. н.

_____ А. В. Николаев

Выпускная квалификационная работа

**Разработка инструмента для визуализации и
прототипирования алгоритмов оценки качества
изображений**

по направлению

01.03.02 Прикладная математика и информатика

Научный руководитель

ст. преп

_____ А. Г. Седов

«_____» _____ 2026 г.

Студент группы ИВТ-41БО

_____ А. С. Кунашев

«_____» _____ 2026 г.

Ярославль, 2026

Реферат

Объем 12 с., 1 гл., 0 рис., 0 табл., 4 источников, 0 прил.

Ключевые слова: **оценка качества изображений, безэталонная метрика, BRISQUE, визуализация, Electron, TypeScript, MSCN, desktop-приложение**

Цель работы – разработать инструмент для визуализации алгоритмов оценки качества изображений и интерактивного изучения их работы на выбранных фрагментах изображения.

В работе рассмотрен подход к безэталонной оценке качества изображений на примере алгоритма BRISQUE. Спроектировано и реализовано desktop-приложение на платформе Electron с использованием TypeScript.

Программа выполняет поэтапное вычисление метрики и наглядно представляет промежуточные результаты: пространственные карты локальной нормализации и попарных коэффициентов, статистические распределения коэффициентов, извлечённые признаки из карт и итоговую оценку качества. Вычисления вынесены в Web Worker, что сохраняет отзывчивость интерфейса при обработке изображений. Разработанное решение может применяться при изучении и отладке алгоритмов оценки качества изображений в учебных и исследовательских задачах.

Содержание

Введение	4
1. Теоретические основы и выбор средств реализации	6
1.1. Оценка качества цифровых изображений	6
1.2. Алгоритм BRISQUE	7
1.2.1. Локальная нормализация MSCN	7
1.2.2. Аппроксимация распределения (Обобщенное распределение Гаусса)	8
1.2.3. Попарные произведения	9
1.2.4. Многомасштабный анализ	10
1.2.5. Регрессия качества	10
Список литературы	12

Введение

Алгоритмы оценки качества изображений позволяют автоматически судить о степени искажения снимка: насколько заметны шум, размытие, артефакты сжатия. Такие метрики нужны при контроле качества видеопотока, отборе данных для обучения моделей. Значительная часть практически значимых методов относится к классу *безэталонных* – они не требуют исходного «чистого» изображения и работают только с тем файлом, который нужно оценить. Среди них популярен алгоритм BRISQUE (*Blind/Referenceless Image Spatial Quality Evaluator*): он строит статистическое описание локальных коэффициентов контраста и на его основе выдаёт одно число – оценку качества.

При этом сам BRISQUE устроен не как «чёрный ящик». Между входным пикселем и итоговым score проходит цепочка осмысленных шагов: локальная нормализация (MSCN), попарные произведения коэффициентов в нескольких направлениях, подбор параметров обобщённых гамма-распределений, формирование 36-мерного вектора признаков и регрессия опорных векторов. Каждый из этих этапов имеет наглядную интерпретацию – пространственные карты, гистограммы, таблицы параметров. Именно эта многослойность делает метрику удобной для разбора на занятиях и при самостоятельном изучении, но стандартные реализации в OpenCV или MATLAB ограничиваются финальным числом. Увидеть, почему алгоритм поставил такую оценку конкретному фрагменту снимка, с их помощью затруднительно.

В рамках данной работы разрабатывается desktop-приложение, которое вычисляет BRISQUE и одновременно показывает внутреннее устройство метрики. Пользователь загружает изображение, выделяет область интереса и получает не только итоговый score, но и карты промежуточных величин, распределения признаков и сводку параметров моделей. Такой режим работы ориентирован на исследование поведения алгоритма: можно сравнить участки одного кадра, проследить, как меняются карты MSCN при смене фрагмента, сопоставить форму гистограммы с подобранной кривой GGD. Речь идёт прежде всего о визуализации и интерактивном изучении метрики; расширение инструмента на другие алгоритмы оценки качества или изменение их параметров «на лету» в текущей версии не предусмотрено, однако заложенное разделение вычислительного ядра и интерфейса оставляет для этого задел.

Технически приложение построено на Electron и TypeScript: вычисления выполняются в Web Worker, отрисовка – на HTML Canvas. В качестве демонстрационного алгоритма выбран BRISQUE как представитель семейства статистических no-reference метрик с прозрачной внутренней структурой.

Работа посвящена процессу оценки качества цифровых изображений без-эталонными метриками; в фокусе – способы представления таких алгоритмов пользователю и их программная реализация. Требуется создать работоспособный инструмент, в котором расчёт BRISQUE и его поэтапная визуализация объединены в одном рабочем процессе. Для этого необходимо разобраться в теории метрики, спроектировать архитектуру приложения, реализовать пайплайн BRISQUE и под-систему отображения результатов, после чего проверить программу на реальных изображениях.

Материал изложен в двух главах. Первая посвящена постановке задачи оценки качества, описанию BRISQUE и обоснованию выбранного стека. Вторая – устройству и реализации разработанного приложения: от загрузки файла и выделения области до карт, графиков и итоговой оценки.

1. Теоретические основы и выбор средств реализации

1.1. Оценка качества цифровых изображений

Под *качеством изображения* в контексте обработки сигналов понимают степень сохранения визуально значимой информации после кодирования, передачи по каналу связи, восстановления из сжатых данных или иных преобразований. Формализовать это понятие можно через субъективные эксперименты: группе наблюдателей демонстрируют серию искаженных изображений, после чего их субъективные оценки усредняются для получения дифференциальной средней оценки (*Differential Mean Opinion Score*, DMOS). Данный показатель характеризует степень различимости искажений: чем выше значение DMOS, тем более выраженными являются артефакты и тем ниже воспринимаемое качество снимка. Такие испытания точны, но дороги и плохо масштабируются, поэтому на практике применяют *объективные метрики* — функции, которые по паре или одному изображению выдают число, коррелирующее с субъективным качеством.

По наличию эталона метрики делят на три класса (табл. 1.1).

Таблица 1.1

Классы объективных метрик качества изображений

Класс	Эталон	Типичное применение
Full-Reference (FR)	Исходное изображение без искажений	Лабораторные эксперименты, настройка кодеков при наличии оригинала
Reduced-Reference (RR)	Часть информации об оригинале	Системы с ограниченным каналом обратной связи
No-Reference (NR)	Не требуется	Видеонаблюдение, потоковое вещание, архивы без источников

Исторически первыми и наиболее простыми в реализации являются FR-метрики. Классический пример такого подхода — среднеквадратичная ошибка (MSE) между матрицами пикселей эталона и искажённого кадра. Обладая высокой скоростью расчета, MSE, тем не менее, демонстрирует слабую корреляцию с восприятием человека: идентичные значения среднеквадратичной ошибки могут соответствовать совершенно разным по характеру и степени заметности визуальным артефактам. Более совершенные FR-подходы (SSIM, MS-SSIM, VIF) учитывают локальную контрастность и особенности человеческого зрения, однако их интеграция ограничена обязательным требованием наличия идеального оригинала.

В ситуациях, когда передача или хранение эталона невозможны, а также в рамках систем с ограниченным каналом обратной связи, могут использоваться метрики с частичным эталоном (RR). Тем не менее, наиболее универсальным и автономным решением являются метрики без эталона (No-Reference, NR), часто называемые «слепыми».

Современные NR-алгоритмы анализируют внутренние статистические свойства самого цифрового снимка на предмет отклонения от математической модели «естественного» неискаженного изображения, либо используют методы машинного обучения, обучая регрессионные модели на предварительно размеченных субъективных датасетах.

Среди существующих NR-подходов выделяют методы на основе анализа частотных преобразований (дискретного косинусного или вейвлет-преобразования), а также методы исследования локальных статистических закономерностей распределения яркости пикселей в пространственной области. Последние представляют особый интерес для проектирования систем визуального контроля: их промежуточные расчетные величины (такие как локальные карты средних значений, карты контрастности и гистограммы нормированных отклонений) имеют строгую физическую и наглядную интерпретацию. Именно это аналитическое свойство пространственных статистических моделей используется в качестве базиса визуализации в разрабатываемом программном инструменте.

1.2. Алгоритм BRISQUE

В качестве базового алгоритма выбран BRISQUE (*Blind/Referenceless Image Spatial Quality Evaluator*) [1] — безэталонная метрика, работающая непосредственно в пространственной области пикселей. Данный подход не требует применения ресурсоемких нейросетевых архитектур или частотных преобразований.

Фундаментальная гипотеза алгоритма опирается на модель статистики естественных сцен (*Natural Scene Statistics*, NSS) [2]. Суть гипотезы заключается в том, что качественные (неискаженные) природные изображения обладают специфическими статистическими свойствами, которые неизбежно нарушаются при внесении артефактов (например, размытия, сжатия или белого шума). Ниже описаны этапы алгоритма, которые затем реализуются в разрабатываемом программном обеспечении для наглядной визуализации.

1.2.1. Локальная нормализация MSCN

На первом этапе яркость входного изображения переводится в оттенки серого по стандарту ITU-R BT.601. Для устранения локальной зависимости от среднего уровня освещенности и выделения структурной информации применяется нормализация локального контраста. Для каждого пикселя с координатами (x, y)

вычисляются локальное среднее $\mu(x, y)$ и локальное стандартное отклонение $\sigma(x, y)$ по формулам:

$$\mu(x, y) = \sum_{k=-K}^K \sum_{l=-L}^L w_{k,l} I(x + k, y + l),$$

$$\sigma(x, y) = \sqrt{\sum_{k=-K}^K \sum_{l=-L}^L w_{k,l} (I(x + k, y + l) - \mu(x, y))^2},$$

где $w_{k,l}$ — двумерная симметричная функция гауссова окна размером $(2K + 1) \times (2L + 1)$. В классической реализации радиус окна составляет $K = L = 3$ (окно 7×7).

Нормализованный коэффициент MSCN (*Mean Subtracted Contrast Normalized*) определяется как:

$$\hat{I}(x, y) = \frac{I(x, y) - \mu(x, y)}{\sigma(x, y) + C},$$

где $C = 1$ — константа стабилизации, предотвращающая деление на ноль в однородных областях с нулевой дисперсией. Карты μ и σ физически отражают базовую освещённость и локальный контраст соответственно, в то время как карта $\hat{I}$ (коэффициенты MSCN) содержит декоррелированную текстурную информацию.

Для естественных снимков гистограмма $\hat{I}$ имеет гауссоподобный вид, что отмечал Ruderman [3]. Искажения смещают эту статистику: размытие делает распределение заметно острее (пик у нуля усиливается, α уменьшается), белый шум, напротив, утяжеляет хвосты гистограммы.

1.2.2. Аппроксимация распределения (Обобщенное распределение Гаусса)

Для математического описания формы гистограммы MSCN-коэффициентов, оригинальный алгоритм применяет аппроксимацию с помощью обобщенного распределения Гаусса (GGD). Функция плотности вероятности GGD с нулевым средним имеет вид:

$$f(x; \alpha, \sigma^2) = \frac{\alpha}{2\beta\Gamma(1/\alpha)} \exp\left(-\left(\frac{|x|}{\beta}\right)^\alpha\right),$$

где параметр масштаба β определяется как

$$\beta = \sigma \sqrt{\frac{\Gamma(1/\alpha)}{\Gamma(3/\alpha)}},$$

а $\Gamma(\cdot)$ — гамма-функция:

$$\Gamma(a) = \int_0^{\infty} t^{a-1} e^{-t} dt \quad (a > 0).$$

В данной модели параметр α контролирует общую «форму» (shape) распределения, а σ^2 — его дисперсию. Параметры (α, σ^2) оцениваются методом сопоставления моментов [4] и входят в итоговый вектор признаков (табл. 1.2, индексы 0–1).

1.2.3. Попарные произведения

В то время как отдельные коэффициенты MSCN эффективно декоррелируют яркость пикселей в пространственной области, между их непосредственными пространственными соседями в неискаженных изображениях сохраняются упорядоченные статистические взаимосвязи. Внесение артефактов нарушает эту локальную регулярность, изменяя направленную корреляцию между пикселями. Чтобы зафиксировать подобные пространственные и геометрические зависимости, алгоритм BRISQUE вычисляет попарные произведения смежных коэффициентов $\hat{I}$ в четырёх смещениях: горизонтальном (H), вертикальном (V) и двух диагональных (D_1, D_2):

$$\begin{aligned} H(x, y) &= \hat{I}(x, y) \hat{I}(x + 1, y), & V(x, y) &= \hat{I}(x, y) \hat{I}(x, y + 1), \\ D_1(x, y) &= \hat{I}(x, y) \hat{I}(x + 1, y + 1), & D_2(x, y) &= \hat{I}(x, y) \hat{I}(x + 1, y - 1). \end{aligned}$$

На границах кадра, где соседние элементы выходят за пределы матрицы изображения, результирующие значения принудительно обнуляются.

В отличие от центрированных и симметричных коэффициентов MSCN, эмпирические распределения попарных произведений при наличии искажений демонстрируют выраженную асимметрию. Для их точного математического моделирования применяется асимметричное обобщённое гауссово распределение (*Asymmetric Generalized Gaussian Distribution*, AGGD). Функция плотности вероятности AGGD с нулевой модой задается следующей кусочной структурой:

$$f(x; \alpha, \sigma_l^2, \sigma_r^2) = \begin{cases} \frac{\alpha}{(\beta_l + \beta_r) \Gamma(1/\alpha)} \exp \left(- \left(\frac{-x}{\beta_l} \right)^\alpha \right), & \text{при } x < 0, \\ \frac{\alpha}{(\beta_l + \beta_r) \Gamma(1/\alpha)} \exp \left(- \left(\frac{x}{\beta_r} \right)^\alpha \right), & \text{при } x \geq 0, \end{cases}$$

где α — параметр формы, определяющий общую крутизну и «остроту» распределения, а σ_l^2 и σ_r^2 — левая и правая дисперсии, отвечающие за масштаб разброса значений влево и вправо от моды соответственно. Параметры масштабирования

β_l и β_r рассчитываются на основе соответствующих дисперсий:

$$\beta_l = \sigma_l \sqrt{\frac{\Gamma(1/\alpha)}{\Gamma(3/\alpha)}}, \quad \beta_r = \sigma_r \sqrt{\frac{\Gamma(1/\alpha)}{\Gamma(3/\alpha)}}.$$

Помимо параметров формы и масштаба, в качестве четвёртого дескриптора AGGD используется параметр η — теоретическое среднее асимметричного распределения. Для модели AGGD он определяется через параметры масштаба:

$$\eta = (\beta_r - \beta_l) \frac{\Gamma(2/\alpha)}{\Gamma(1/\alpha)}.$$

Вектор $(\alpha, \eta, \sigma_l^2, \sigma_r^2)$, извлекаемый для каждого из четырёх направлений методом сопоставления моментов [4], описывает характер деградации пространственных связей (табл. 1.2, индексы 2–17 на одном масштабе).

1.2.4. Многомасштабный анализ

Искажения проявляются на разных пространственных частотах. BRISQUE повторяет этапы нормализации и попарных произведений на двух масштабах: исходном (*Scale 1*) и уменьшенном в два раза (*Scale 2*). Масштабирование выполняется бикубической интерполяцией по яркостной карте. Для каждого масштаба формируется 18 признаков, итого — 36-мерный вектор.

Таблица 1.2

Признаки BRISQUE на одном масштабе (18 значений)

Индексы	Содержание
0–1	GGD карты MSCN: α, σ^2
2–5	AGGD направления H : $\alpha, \eta, \sigma_l^2, \sigma_r^2$
6–9	AGGD направления V : $\alpha, \eta, \sigma_l^2, \sigma_r^2$
10–13	AGGD направления D_1 : $\alpha, \eta, \sigma_l^2, \sigma_r^2$
14–17	AGGD направления D_2 : $\alpha, \eta, \sigma_l^2, \sigma_r^2$

Признаки Scale 1 занимают позиции 0–17, Scale 2 — 18–35.

1.2.5. Регрессия качества

Итоговая оценка получается методом опорных векторов (SVR) с радиально-базисным ядром. Вектор признаков предварительно линейно масштабируется в диапазон $[-1, 1]$ по минимумам и максимумам, зафиксированным при обучении

на базе LIVE. Предсказание имеет вид

$$\widehat{\text{DMOS}} = \sum_{i=1}^N \alpha_i K(\mathbf{x}, \mathbf{x}_i) - \rho, \quad K(\mathbf{x}, \mathbf{x}_i) = \exp(-\gamma \|\mathbf{x} - \mathbf{x}_i\|^2),$$

где $\mathbf{x}$ — масштабированный 36-мерный вектор, $\mathbf{x}_i$ — опорные векторы, α_i, ρ, γ — параметры обученной модели.

Список литературы

- [1] No-Reference Image Quality Assessment in the Spatial Domain [Электронный ресурс]. URL: <https://live.ece.utexas.edu/publications/2012/TIP%20BRISQUE.pdf> (дата доступа: 19.04.2026).
- [2] On Advances in Statistical Modeling of Natural Images [Электронный ресурс]. URL: <http://www.stat.ucla.edu/~sczhu/papers/srivastavapaper.pdf> (дата доступа: 19.04.2026).
- [3] On Advances in Statistical Modeling of Natural Images [Электронный ресурс]. URL: https://www.researchgate.net/publication/3813454_Statistics_of_natural_images_and_models (дата доступа: 19.04.2026).
- [4] Estimation of Shape Parameter for Generalized Gaussian Distributions in Subband Decompositions of Video [Электронный ресурс]. URL: - (дата доступа: 19.04.2026).